

u^b

b
UNIVERSITÄT
BERN

OESCHGER CENTRE
CLIMATE CHANGE RESEARCH

STATISTISCHE TESTS TEIL 2

KONFIDENZINTERVALLE

Bahrenberg I: Kap. 5;
Ernste Anh. B;
Ewing I: Kap. 10

T-Test für den Mittelwert

(Vergleich von Stichprobemittel und mit fixem Wert,
z.B. bekanntem Mittel der GG oder Grenzwert)

Hypothesen:

H_0 : Erwartete Sept.-Nov. Mitteltemperatur beträgt 9°C ($x = \mu_0$)

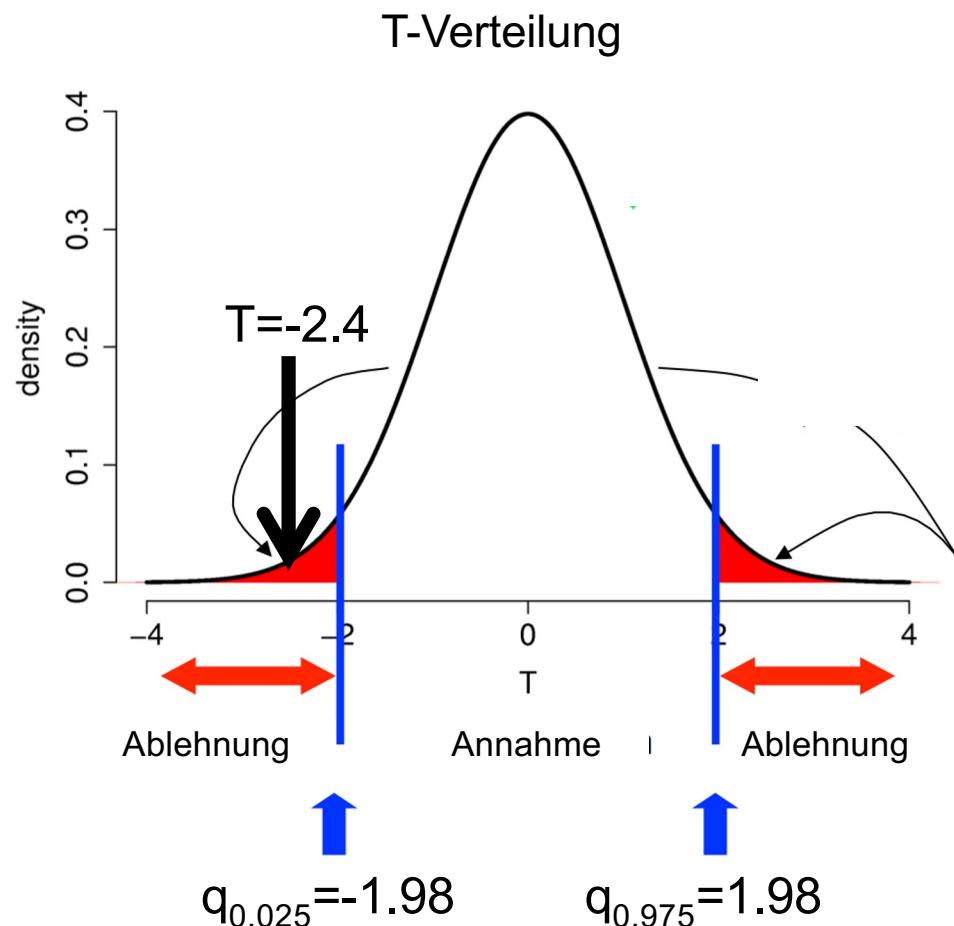
H_A : Die Temperatur weicht signifikant von 9°C ab ($x \neq \mu_0$)

Teststatistik: $T = \frac{\bar{x} - \mu_0}{s_x}$ $x=8.75^\circ\text{C}$, $s_x=0.10^\circ\text{C}$, $n=111$, $T=-2.40$

ähnlich der Standardisierung / Z-Transformation / Standardnormalverteilung

mit dem Standardfehler $s_x = \sqrt{\frac{s^2}{n}}$

T-Test für den Mittelwert



Test

- Wert von $T (= -2.40)$ ist im Ablehnungsbereich
- Stichprobenmittelwert unterscheidet sich von Erwartungswert (9°C) auf dem 5% Signifikanzlevel.
- Test p-Wert von 0.018

p-Wert

- Das kleinste α für das H_0 abgelehnt würde

Testtheorie

Hypothesen aufstellen

u^b

b
UNIVERSITÄT
BERN

OESCHGER CENTRE
CLIMATE CHANGE RESEARCH



Wie im Gericht: Beratungen und Überlegungen

- > Angenommen H_0 ist wahr, wie wahrscheinlich ist es zufällig diesen oder einen grösseren Testwert zu erhalten?
- > Der p-Wert ist die numerische Antwort
- > Je kleiner p, desto stärker die Beweise gegen H_0 (oft 0.05 als Grenze)
- > p-Wert sagt **NICHT**: Wie wahrscheinlich ist es, dass die H_0 wahr ist
- > p-Wert sagt: Wie wahrscheinlich die Daten sind, wenn H_0 wahr ist

Testtheorie

Hypothesen aufstellen

u^b

b
UNIVERSITÄT
BERN

OESCHGER CENTRE
CLIMATE CHANGE RESEARCH



Wie im Gericht: Das Urteil

Option 1:

wichtig!

- > grosser p-Wert ($p > \alpha$, z.B. mit $\alpha=0.05$ für 95%ige Sicherheit)
- > wir schliessen daraus -> Daten sind konsistent mit H_0

Option 2:

- > kleiner p-Wert ($p < \alpha$)
- > wir schliessen daraus -> es gibt ausreichend Beweise, um H_0 abzulehnen und H_A anzunehmen (statistisch signifikant).

- > Eine Masszahl für die Unsicherheit der Parameterschätzung
- > Wertebereich eines Parameters, für den H_0 nicht abgelehnt wird
- > Eng verknüpft mit dem Signifikanzlevel α !

Beispiel:

$$T = \frac{\bar{x} - \mu_0}{s_{\bar{x}}} \Rightarrow \mu \in \left\{ \bar{x} \pm q_{T,0.975} \cdot s_{\bar{x}} \right\}$$



in diesem Beispiel das 0.975 Quantil der T-Verteilung mit $n-1$ Freiheitsgraden.
 n : Stichprobengrösse

Konfidenzintervalle

- > Wie repräsentativ sind unsere Stichprobenergebnisse für die Grundgesamtheit?
- > Wir wollen den Unsicherheitsbereich um den Stichprobenmittelwert bestimmen, sogenanntes Konfidenzintervall:

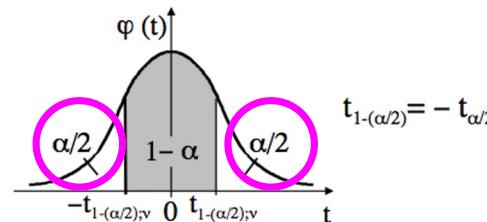
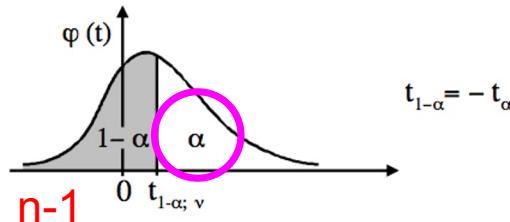
$$\mu_{Obergrenze} = \bar{x} + q_{1-\alpha} \cdot \sqrt{\frac{s^2}{n}}$$

(identisch mit vorheriger Folie,
nur inklusive Berechnung der
Standardfehlers!)

$$\mu_{Untergrenze} = \bar{x} - q_{1-\alpha} \cdot \sqrt{\frac{s^2}{n}}$$

- > q abzulesen aus t-Tabelle normalerweise für den zweiseitigen Test (wenn Ober- und Untergrenze des Konfidenzintervals bestimmt werden), n-1 Freiheitsgrade und α oder aus
- > R: `t.test(x, alternative = ("two.sided" ODER "less" ODER "greater"), conf.level = 0.95, ...)`
- > Excel Funktion T.INV bzw. T.INV.2T, Excel Funktion T.TEST (zur Bestimmung des p-Wertes).

t-Verteilungs Tabelle



FG

v	Statistische Sicherheit $1-\alpha$					
	0,90	0,95	0,975	0,99	0,995	0,999
1	3,078	6,314	12,71	31,82	63,66	318,3
2	1,886	2,920	4,303	6,965	9,925	22,33
3	1,638	2,353	3,182	4,541	5,841	10,21
4	1,533	2,132	2,776	3,747	4,604	7,173
5	1,476	2,015	2,571	3,365	4,032	5,893
6	1,440	1,943	2,447	3,143	3,707	5,208
7	1,415	1,895	2,365	2,998	3,499	4,785
8	1,397	1,860	2,306	2,896	3,355	4,501
9	1,383	1,833	2,262	2,821	3,250	4,297
10	1,372	1,812	2,228	2,764	3,169	4,144
11	1,363	1,796	2,201	2,718	3,106	4,025
12	1,356	1,782	2,179	2,681	3,055	3,930
13	1,350	1,771	2,160	2,650	3,012	3,852
14	1,345	1,761	2,145	2,624	2,977	3,787
15	1,341	1,753	2,131	2,602	2,947	3,733
16	1,337	1,746	2,120	2,583	2,921	3,686
17	1,333	1,740	2,110	2,567	2,898	3,646
18	1,330	1,734	2,101	2,552	2,878	3,610
19	1,328	1,729	2,093	2,539	2,861	3,579
20	1,325	1,725	2,086	2,528	2,845	3,552
21	1,323	1,721	2,080	2,518	2,831	3,527
22	1,321	1,717	2,074	2,508	2,819	3,505
23	1,319	1,714	2,069	2,500	2,807	3,485
24	1,318	1,711	2,064	2,592	2,797	3,467
25	1,316	1,708	2,060	2,485	2,787	3,450
26	1,315	1,706	2,056	2,479	2,779	3,435
27	1,314	1,703	2,052	2,473	2,771	3,421
28	1,313	1,701	2,048	2,467	2,763	3,408
29	1,311	1,699	2,045	2,462	2,756	3,396
30	1,310	1,697	2,042	2,457	2,750	3,385
40	1,303	1,684	2,021	2,443	2,704	3,307
50	1,299	1,676	2,009	2,403	2,678	3,261
60	1,296	1,671	2,000	2,390	2,660	3,232
70	1,294	1,667	1,994	2,381	2,648	3,211
80	1,292	1,664	1,990	2,374	2,639	3,195
90	1,291	1,662	1,987	2,368	2,632	3,183
100	1,290	1,660	1,984	2,364	2,626	3,174
200	1,286	1,652	1,972	2,345	2,601	3,131
500	1,283	1,648	1,965	2,334	2,586	3,107
∞	1,282	1,645	1,960	2,326	2,576	3,090

oder entsprechend -1.98

v	Statistische Sicherheit $1-\alpha$						
	0,80	0,90	0,95	0,98	0,99	0,998	0,999
1	3,078	6,314	12,71	31,82	63,66	318,3	636,6
2	1,886	2,920	4,303	6,965	9,925	22,33	31,60
3	1,638	2,353	3,182	4,541	5,841	10,21	12,92
4	1,533	2,132	2,776	3,747	4,604	7,173	8,610
5	1,476	2,015	2,571	3,365	4,032	5,893	6,869
6	1,440	1,943	2,447	3,143	3,707	5,208	5,959
7	1,415	1,895	2,365	2,998	3,499	4,785	5,408
8	1,397	1,860	2,306	2,896	3,355	4,501	5,041
9	1,383	1,833	2,262	2,821	3,250	4,297	4,781
10	1,372	1,812	2,228	2,764	3,169	4,144	4,587
11	1,363	1,796	2,201	2,718	3,106	4,025	4,437
12	1,356	1,782	2,179	2,681	3,055	3,930	4,318
13	1,350	1,771	2,160	2,650	3,012	3,852	4,221
14	1,345	1,761	2,145	2,624	2,977	3,787	4,140
15	1,341	1,753	2,131	2,602	2,947	3,733	4,073
16	1,337	1,746	2,120	2,583	2,921	3,686	4,015
17	1,333	1,740	2,110	2,567	2,898	3,646	3,965
18	1,330	1,734	2,101	2,552	2,878	3,610	3,992
19	1,328	1,729	2,093	2,539	2,861	3,579	3,883
20	1,325	1,725	2,086	2,528	2,845	3,552	3,850
21	1,323	1,721	2,080	2,518	2,831	3,527	3,819
22	1,321	1,717	2,074	2,508	2,819	3,505	3,792
23	1,319	1,714	2,069	2,500	2,807	3,485	3,768
24	1,318	1,711	2,064	2,592	2,797	3,467	3,745
25	1,316	1,708	2,060	2,485	2,787	3,450	3,725
26	1,315	1,706	2,056	2,479	2,779	3,435	3,707
27	1,314	1,703	2,052	2,473	2,771	3,421	3,690
28	1,313	1,701	2,048	2,467	2,763	3,408	3,674
29	1,311	1,699	2,045	2,462	2,756	3,396	3,659
30	1,310	1,697	2,042	2,457	2,750	3,385	3,646
40	1,303	1,684	2,021	2,443	2,704	3,307	3,551
50	1,299	1,676	2,009	2,403	2,678	3,261	3,496
60	1,296	1,671	2,000	2,390	2,660	3,232	3,460
70	1,294	1,667	1,994	2,381	2,648	3,211	3,436
80	1,292	1,664	1,990	2,374	2,639	3,195	3,416
90	1,291	1,662	1,987	2,368	2,632	3,183	3,400
100	1,290	1,660	1,984	2,364	2,626	3,174	3,390
200	1,286	1,652	1,972	2,345	2,601	3,131	3,340
500	1,283	1,648	1,965	2,334	2,586	3,107	3,310
∞	1,282	1,645	1,960	2,326	2,576	3,090	3,291

nur der positive Wert angegeben,
beim 2-seitigen Test ist der negative
kritische Grenzwert entsprechend -1.98

95% Konfidenzintervall der erwarteten Temperatur aus dem vorherigen Beispiel:

- > alle Werte, für die T kleiner ist als der kritische Wert mit:
 $x = 8.75^\circ\text{C}$, $s_x = 0.10^\circ\text{C}$, $n = 111$, $q_{T,0.95(\text{zweiseitig})} = 1.98$

Konfidenzintervall:

- > Untergrenze: $8.75 - 1.98 \cdot 0.1 = 8.55^\circ\text{C}$
- > Obergrenze: $8.75 + 1.98 \cdot 0.1 = 8.95^\circ\text{C}$

Anmerkung:

- > 9°C liegt nicht im Konfidenzintervall, was im Einvernehmen mit der vorherigen Ablehnung von H_0 ($\mu = 9$) steht

Daumenregel:

- > Konfidenzintervall = Stichprobenergebnis \pm 2 Standardfehler

Was sind die Voraussetzungen, damit der t-Test angewendet werden darf?

Was sind die Voraussetzungen, damit der t-Test angewendet werden darf?

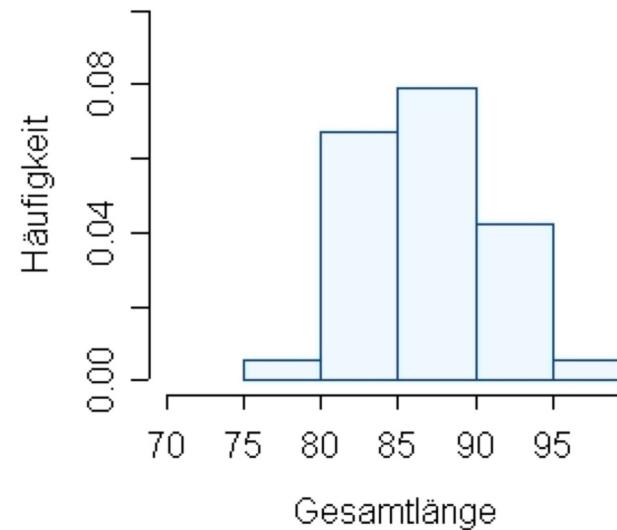
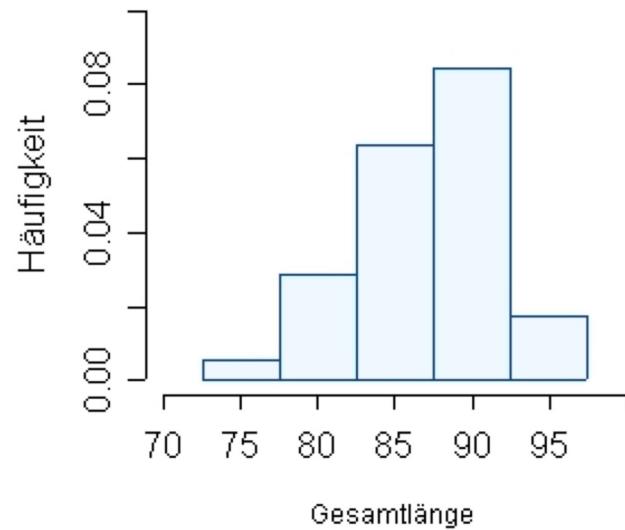
Für den T-Test alles, was Voraussetzung für das arithmetische Mittel ist, d.h. metrische Daten, keine Ausreisser in den Daten, und symmetrische Verteilung

Überprüfung auf Normalverteilung

u^b

b
UNIVERSITÄT
BERN

OESCHGER CENTRE
CLIMATE CHANGE RESEARCH



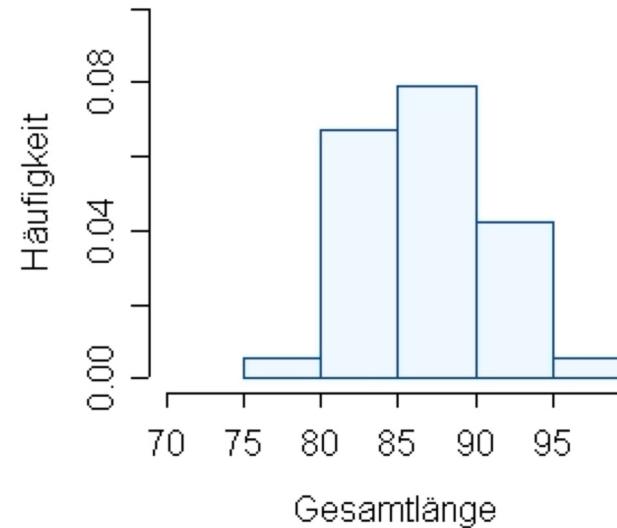
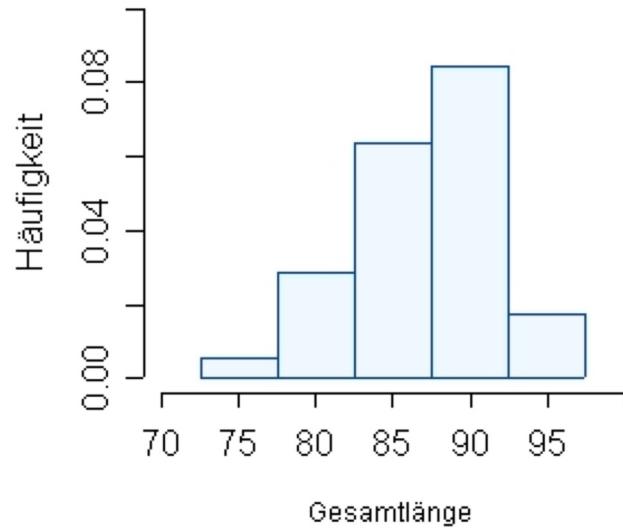
Sind diese Daten normalverteilt?

Überprüfung auf Normalverteilung

u^b

b
UNIVERSITÄT
BERN

OESCHGER CENTRE
CLIMATE CHANGE RESEARCH



Gleiche Daten, aber
visuell unterschiedliche Histogramme

Hypothesen aufstellen

u^b

b
UNIVERSITÄT
BERN

OESCHGER CENTRE
CLIMATE CHANGE RESEARCH

- > Wie lautet H_0 und H_A beim Test, ob die Daten normalverteilt sind?

Hypothesen aufstellen

u^b

b
UNIVERSITÄT
BERN

OESCHGER CENTRE
CLIMATE CHANGE RESEARCH

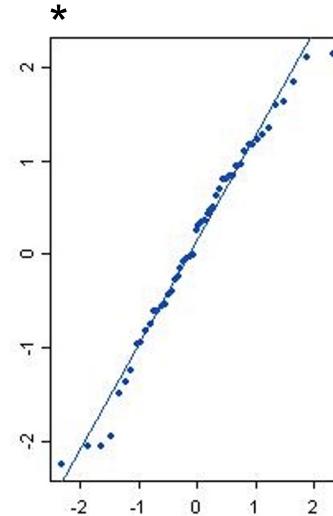
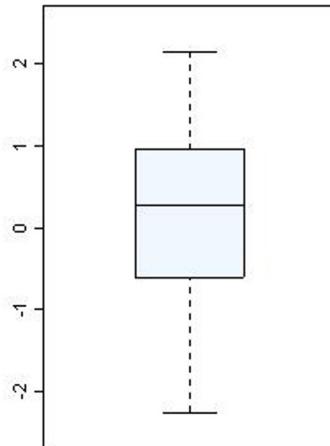
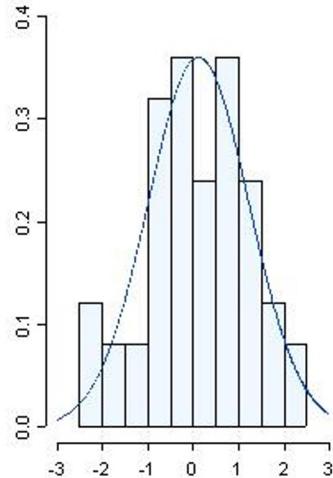
Warum ist Normalverteilung Nullhypothese, wenn man doch gerade beweisen will, dass Daten normalverteilt sind?

Ein Test sagt ja nur gleich oder ungleich bzw. es gibt (nicht) ausreichend Beweise gegen H_0 . Wenn wir nun testen, ob H_0 nicht z.B. gleichverteilt,... ist. Wenn H_0 verworfen werden kann, heisst das aber noch nicht, dass die Daten normalverteilt sind, könnten auch irgendwie anders verteilt sein.

Der einzige Weg, um herauszubekommen, ob die Daten normalverteilt sind, ist also zu prüfen ob man die Hypothese der Normalverteilung widerlegen kann!

Daten sind gleich der Normalverteilung
Das = steht also wieder in H_0

Überprüfung auf Normalverteilung



Kenngroße	Messreihe A	Normalverteilung
(Mittelwert - Median) / s	-0,14	0
IQR / s	1,36	1,34
# 1s Intervall / n	72 %	68 %
# 2s Intervall / n	98 %	95 %
# 3s Intervall / n	100 %	99,73 %

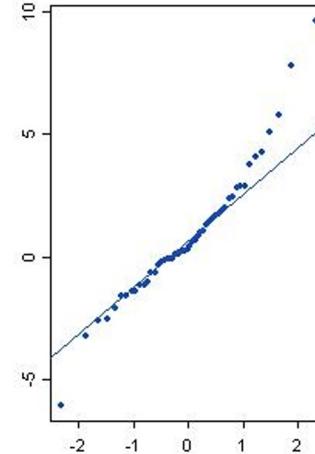
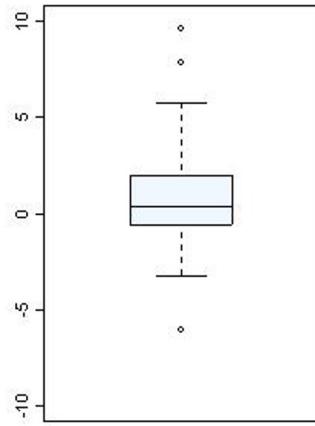
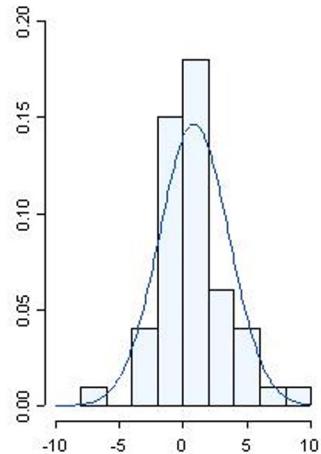
Test	p-Wert
Shapiro-Wilks	0,4544
Anderson-Darling	0,6796
Cramér-von Mises	0,7521

Die p-Werte der Tests auf Normalverteilung sind alle deutlich größer als 0.05, somit wird die Nullhypothese der Normalverteilung beibehalten.

Beim Test auf Normalverteilung wird immer in der Nullhypothese angenommen, dass die Messreihe aus einer Normalverteilung stammt.

*QQ-Plot: Quantile zweier statistischer Variablen gegeneinander abgetragen werden, um ihre Verteilungen zu vergleichen

Überprüfung auf Normalverteilung



Kenngröße	Messreihe B	Normalverteilung
(Mittelwert - Median) / s	0,18	0
IQR / s	0,94	1,34
# 1s Intervall / n	76 %	68 %
# 2s Intervall / n	94 %	95 %
# 3s Intervall / n	98 %	99,73 %

Test	p-Wert
Shapiro-Wilks	0,0303
Anderson-Darling	0,0285
Cramér-von Mises	0,0331

Die p-Werte der Tests auf Normalverteilung lehnen in jedem Fall die Nullhypothese zum Niveau $\alpha=0,05=5\%$ ab

p-Werte sind deutlich kleiner als 0,05, d. h. die Nullhypothese "Messreihe ist normalverteilt" wird verworfen

Überprüfung auf Normalverteilung in R

U^b

^b
UNIVERSITÄT
BERN

OESCHGER CENTRE
CLIMATE CHANGE RESEARCH

Test	Vorteile	Nachteile
Chi-Quadrat-Test	- geeignet für beliebig skalierte Variablen	- Gruppierung der Beobachtungen notwendig - ungeeignet für kleine Stichproben - quadratische Testgrösse, d.h. sensibel auf Ausreisser
Kolmogorov-Smirnov Test	- geeignet für kleine Stichproben - wie Chi-Quadrat auch zum Vergleich anderer Verteilungen geeignet - nicht-parametrischer Test, d.h. NICHT sensibel auf Ausreisser	- geringe Teststärke im Vergleich zu den folgenden Tests
Cramér-von-Mises-Test	- höhere Güte als KS-Test	- quadratische Testgrösse
Lilliefors-Test	- bessere Trennschärfe als KS-Test - nicht-parametrischer Test, d.h. NICHT sensibel auf Ausreisser	- nur zum Test auf Normalverteilung
Anderson-Darling-Test	- sehr hohe Güte bei Test auf Normalverteilung	- keine kategorialen Daten - quadratische Testgrösse, d.h. sensibel auf Ausreisser
Shapiro-Wilk-Test	- Test mit höchster Güte	- ausschließlich Test auf Normalverteilung - manuell schlecht durchführbar - sensibel auf Ausreisser und viele identische Werte

Überprüfung auf Normalverteilung in R

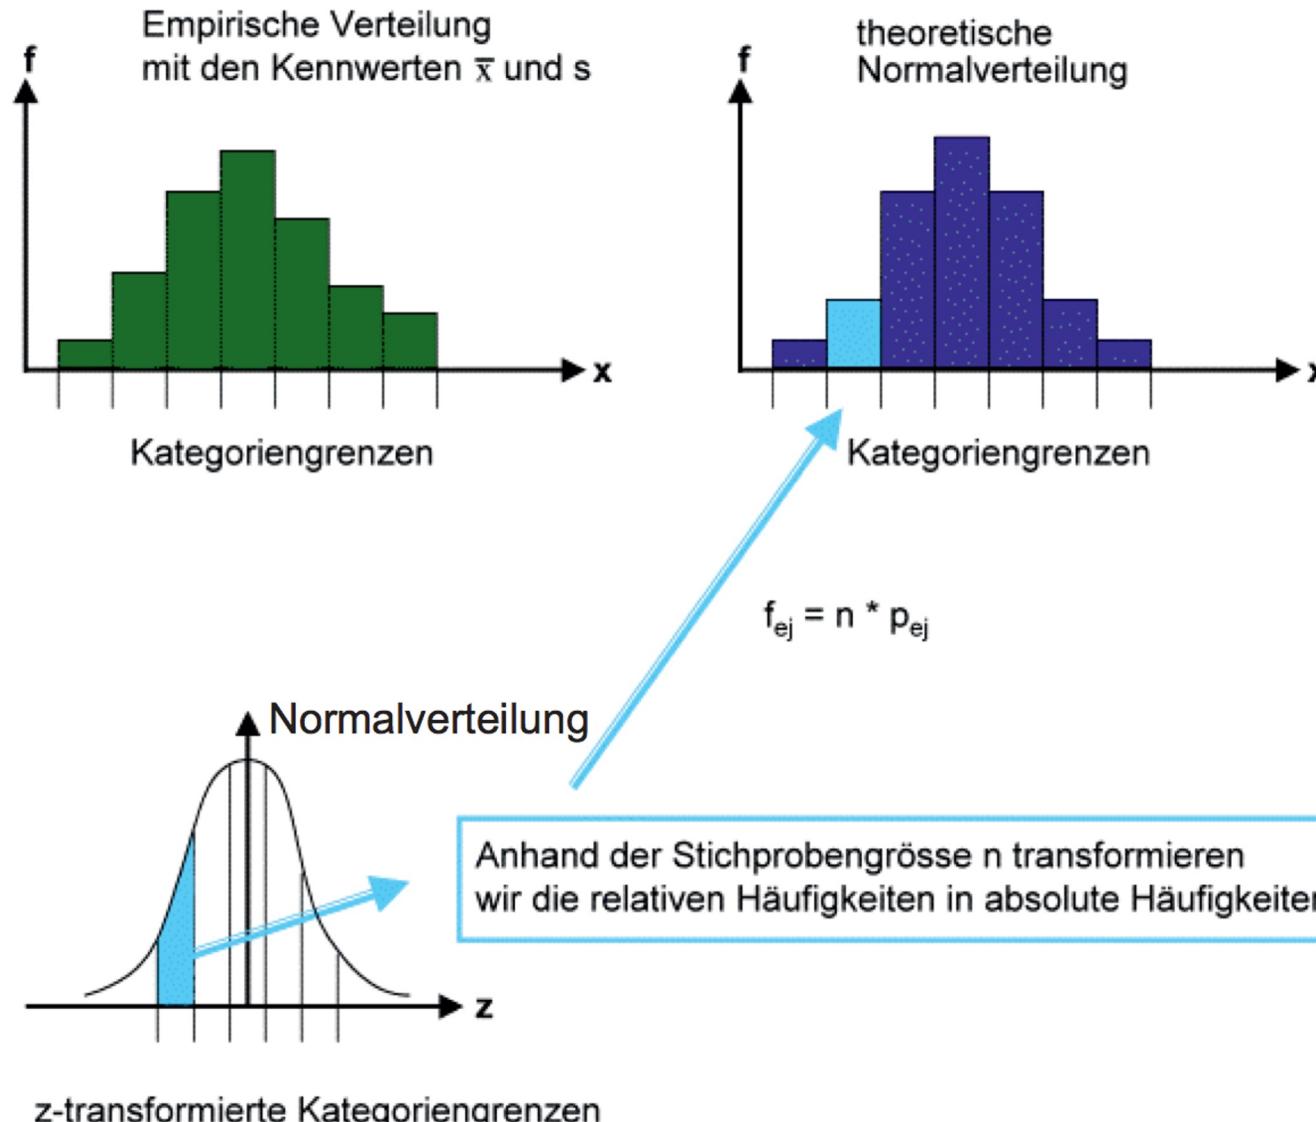


b
UNIVERSITÄT
BERN

OESCHGER CENTRE
CLIMATE CHANGE RESEARCH

```
> data <- rnorm(500) # 500 normalverteilte Zufallszahlen
> data2 <- data^2      # quadrierte Zufallszahlen
> hist(data)           # Histogramm
> plot(density(data)) # Dichtefunktion
> boxplot(data)        # Boxplot
> qqnorm(data)         # Quantil-Quantil Plot
> qqline(data, col = 2) # Erwartung bei Normalverteilung
> shapiro.test(data)  # Shapiro Normalverteilungstest
```

χ^2 Test auf Normalverteilung



Allgemeiner Test für Verteilungen

χ^2 -Verteilungstest

u^b

b
UNIVERSITÄT
BERN

OESCHGER CENTRE
CLIMATE CHANGE RESEARCH

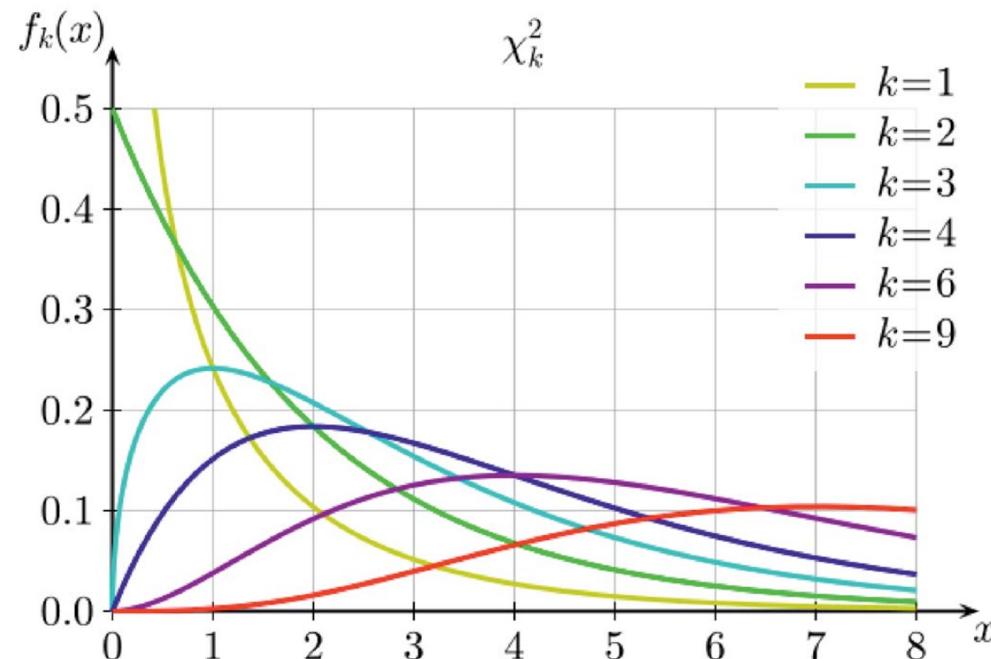
- > Summe der normierten quadrierten Abweichungen:

$$\chi^2 = \sum_{i=1}^k \frac{(N_i - n_i)^2}{n_i}$$

- > N beobachtete Häufigkeit
- > n erwartete Häufigkeit
- > i Klassen
- > k Anzahl an Klassen

χ^2 -Verteilung

- > Stetige Wahrscheinlichkeitsverteilung mit der Anzahl Freiheitsgrade k als einzigem Parameter.
- > Verteilung der Summe der Quadrate von k unabhängigen und standardnormalverteilten Zufallsvariablen.



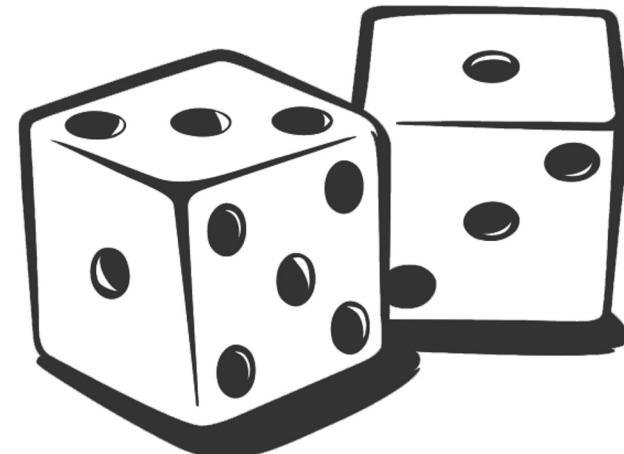
Würfelergebnisse

u^b

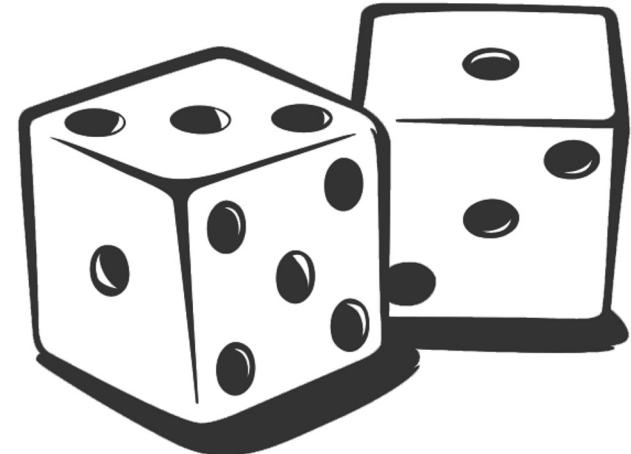
b
UNIVERSITÄT
BERN

OESCHGER CENTRE
CLIMATE CHANGE RESEARCH

- > Was sind die Null-, und Alternativhypothese unseres Würfelexperiments?



Würfelergebnisse



- > Was sind die Null-, und Alternativhypothese unseres Würfelexperiments?
- > H_0 : Die Verteilung der gewürfelten Zahlen entspricht den theoretischen Wahrscheinlichkeiten
- > H_A : Die Verteilung der gewürfelten Zahlen entspricht NICHT den theoretischen Wahrscheinlichkeiten

Richtigen Test und statistische Verfahren finden

u^b

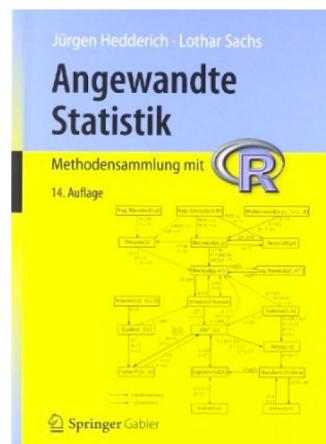
^b
UNIVERSITÄT
BERN

OESCHGER CENTRE
CLIMATE CHANGE RESEARCH

Chatbot?

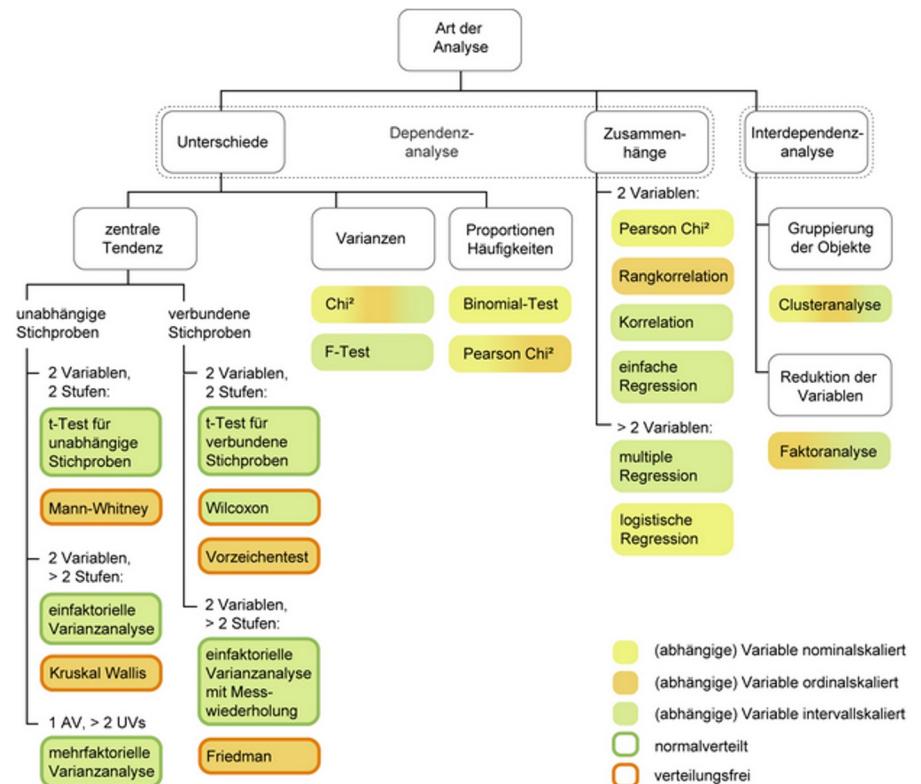
Bücher:

- > Ernste S. 21 ff.
- > Jürgen Hedderich, Lothar Sachs,
2012: Angewandte Statistik:
Methodensammlung mit R. Springer

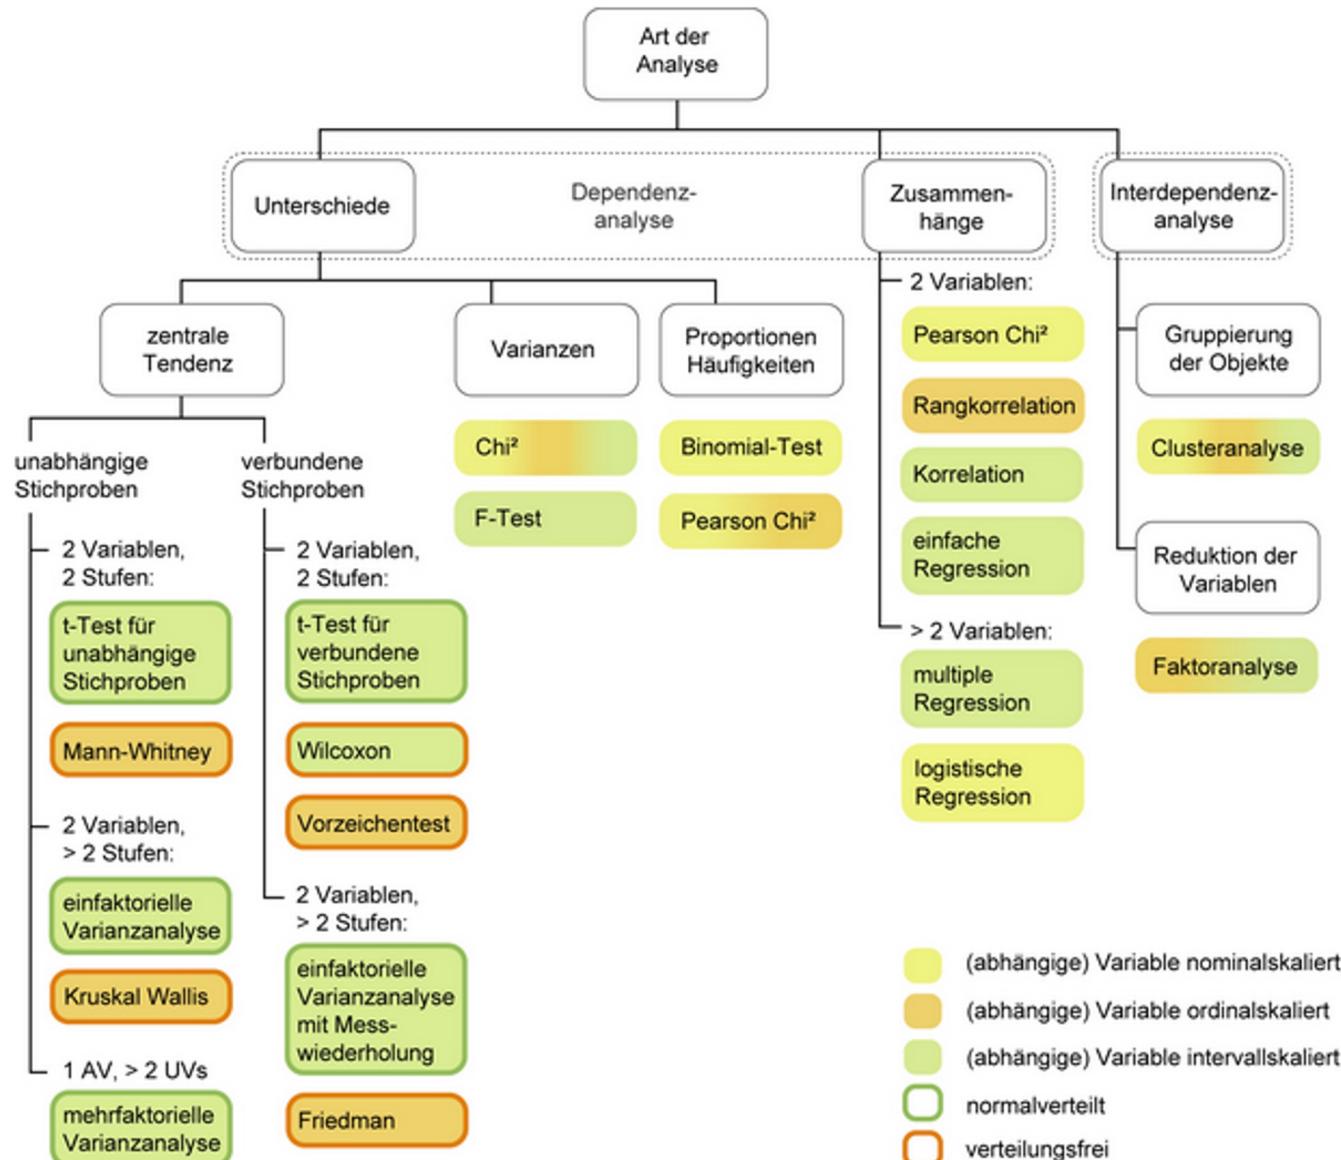


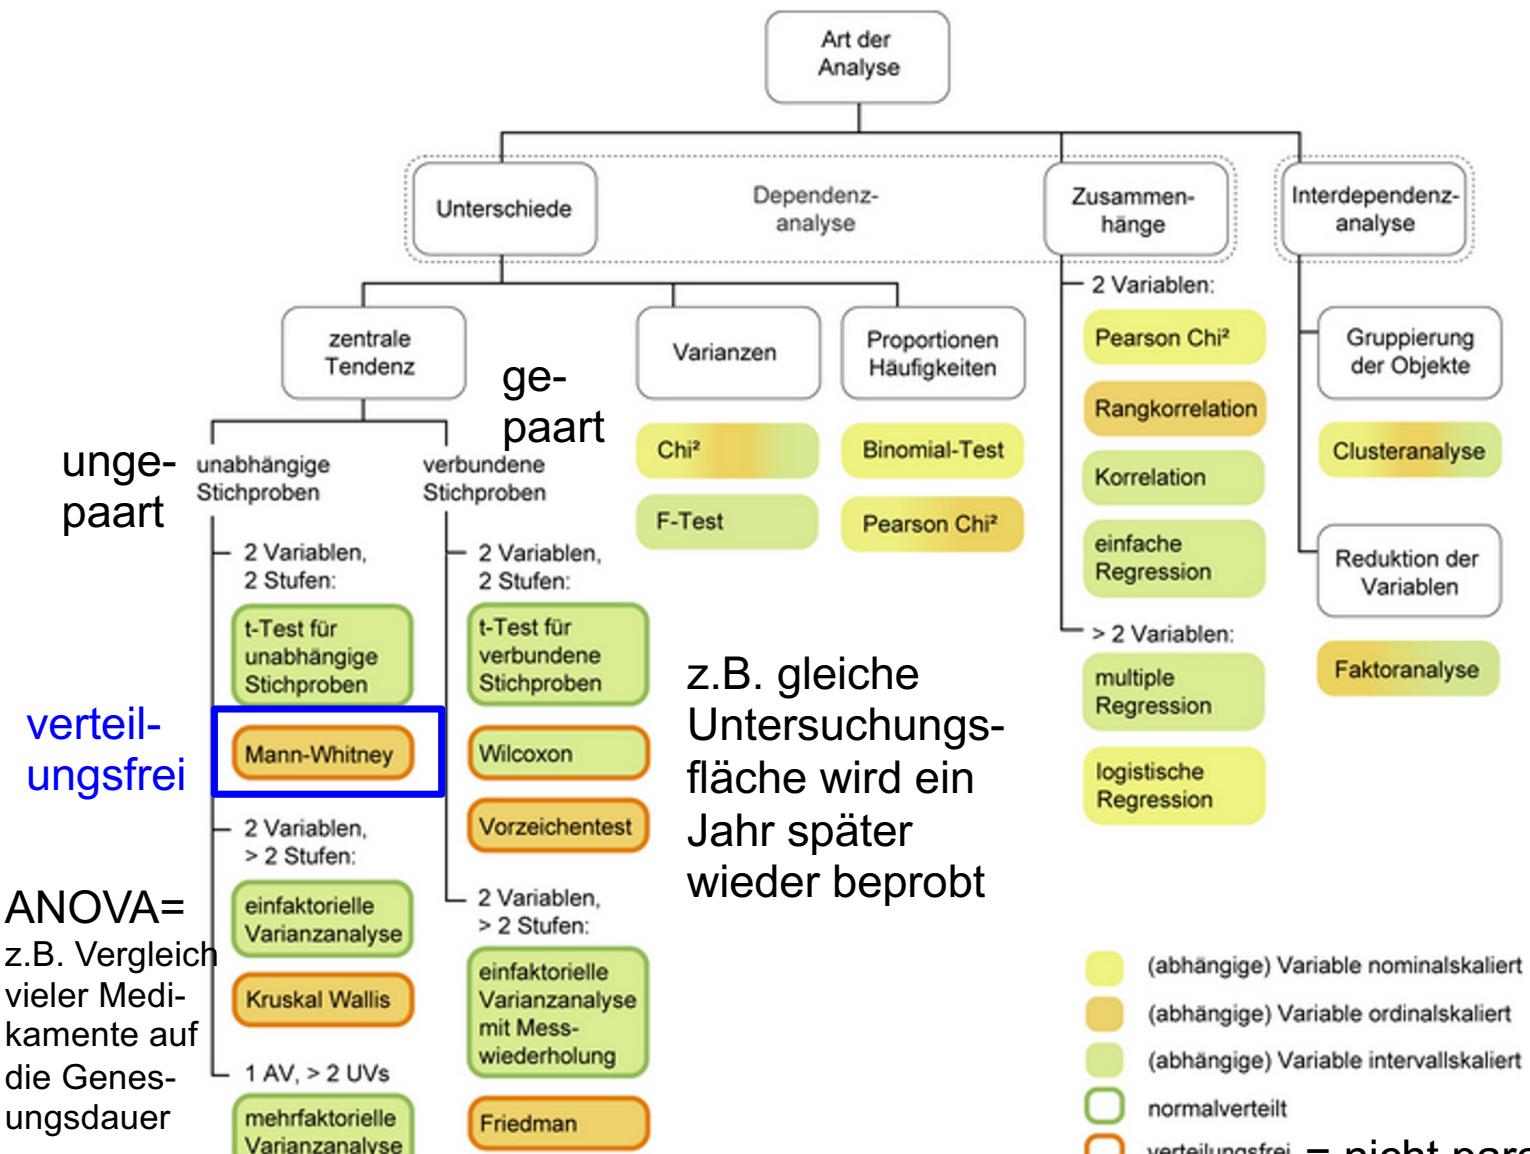
Entscheidungsbäume

- > <http://www.methodenberatung.uzh.ch/index.html>
- > <http://etools.fernuni.ch/entscheidungsbaum/>



Angenommen ihr wollt Winter- und Sommermittelwerte von nicht-normalverteilten Niederschlagssummen vergleichen.
Welchen Test müsst ihr nehmen?





ANOVA=
z.B. Vergleich
vieler Medi-
kamente auf
die Genes-
ungsdauer

AV=abhängige Variable
UV=unabhängige Variable

- (abhängige) Variable nominalskaliert
- (abhängige) Variable ordinalskaliert
- (abhängige) Variable intervallskaliert
- normalverteilt
- verteilungsfrei = nicht parametrische Tests

Verfahren kann oft auch für metrische Daten verwendet werden, die nicht normalverteilt sind

Take-home Message

u^b

b
UNIVERSITÄT
BERN

OESCHGER CENTRE
CLIMATE CHANGE RESEARCH

Standardvorgehen bei statistischen Tests:

1. Hypothesen aufstellen
2. Schwellenwert festlegen (z.B. $\alpha = 0.05$, d.h. bei jedem 20. Test eine falsche Entscheidung)
3. Ziehung der Stichprobe
- 4.1. Traditionelle und manuelle Zusammenfassung der Daten in einem Wert (einer Teststatistik) und Vergleich ob im Annahme- oder Ablehnungsbereich mithilfe einer Tabelle **oder**
- 4.2. p(robability)-Wert durch Software ermitteln. Wenn der p-Wert < als z.B. 0.05 ist bedeutet dies, dass es eine sehr kleine (<5%) Wahrscheinlichkeit gibt, die Stichprobe zu erhalten, wenn die Nullhypothese wahr ist **oder**
- 4.3. Konfidenzintervalle bestimmen. Diese beschreiben (z.B. für den Mittelwert) einer Stichprobe, den Bereich in dem z.B. mit 95% Sicherheit der entsprechende Wert (hier Mittelwert) Grundgesamtheit liegt.

Schliessende Statistik beruht meist auf Wahrscheinlichkeiten und liefert uns KEINE 100% sicheren Ergebnisse!

Enger mathematischer Zusammenhang zwischen Tests und Konfidenzintervallen

Alle Tests funktionieren nach ähnlichem Muster: Wenn ihr einen Verstanden habt, könnt ihr jeden beliebigen Test in eurer eigenen Arbeit anwenden. Webseiten und Bücher helfen den richtigen Test zu finden, enthalten Informationen über Freiheitsgrade, etc.

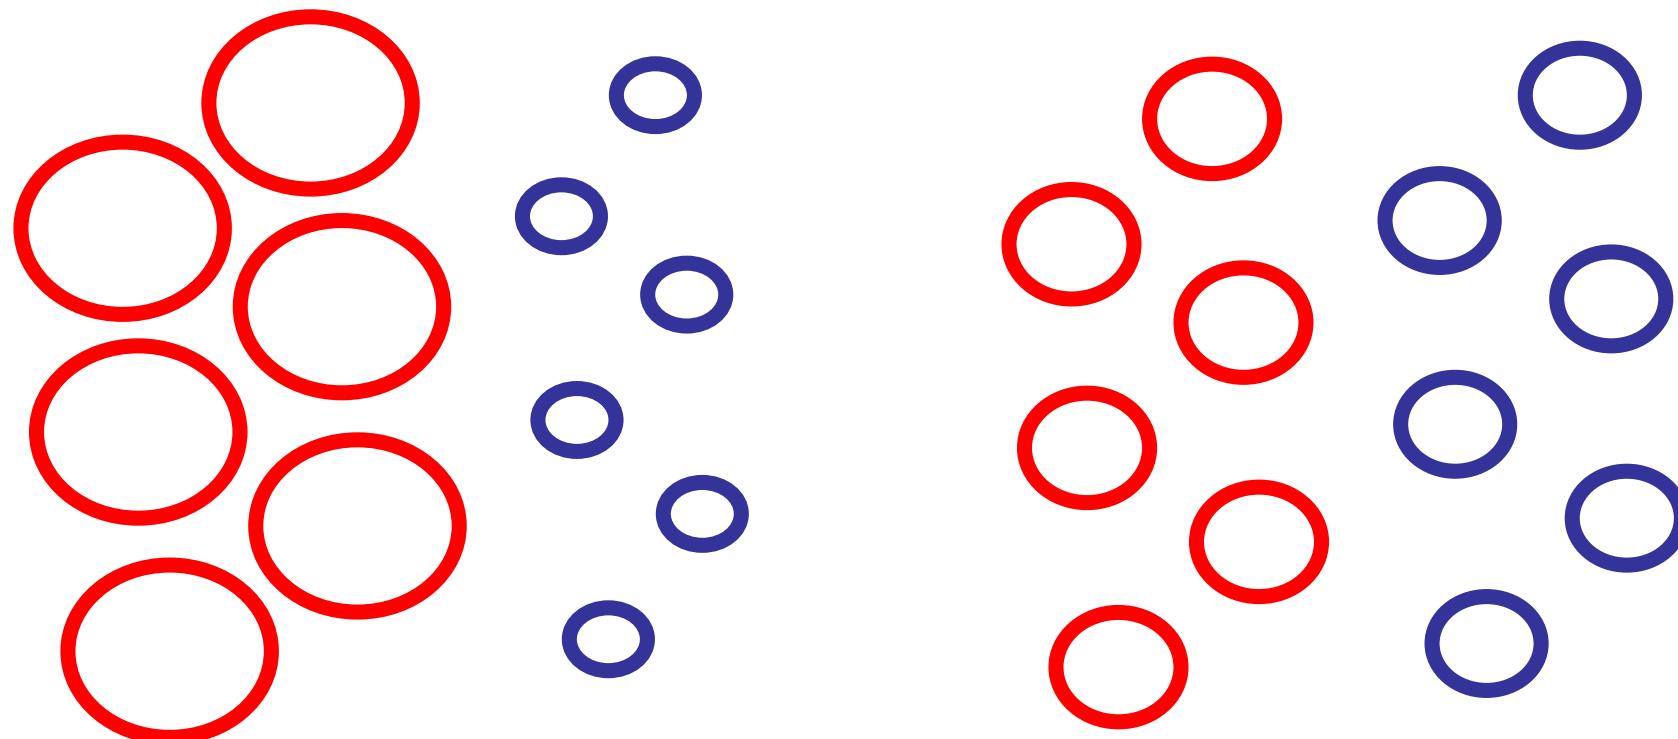
Statistisch signifikant

- > Eine Studie mit 10000 Personen zeigt, dass ein neues Medikament die Dauer einer Grippe statistisch signifikant ($\alpha < 0.05$) um eine Stunde verkürzt.
- > Was haltet ihr von dem Medikament?

ACHTUNG:

Bei einer grossen Stichprobe kann auch ein kleiner Unterschied statistisch signifikant sein

- > Ob die Grösse des Unterschieds eine Bedeutung hat, müsst ihr interpretieren:
- > **Grösse des Effekts**



Beispiel Prüfungsfrage

- > Was versteht man in der Statistik unter dem “Standardfehler”?
 - Abweichungen der Stichprobenwerte vom Stichprobenmittelwert
 - Abweichungen der Stichprobenmittelwerte vom Mittelwert der Grundgesamtheit
 - Die Varianz der Mittelwerte von mehreren Stichproben der gleichen Grundgesamtheit
 - Die Varianz der Stichprobenwerte von Stichproben aus verschiedenen Grundgesamtheiten
- > Interpretiert die R Ausgabe mit dem Ergebnis eines t-Tests (siehe Übung aus Teil 1)
- > Welcher statistische Test eignet, um die Mittelwerte nicht normalverteilter, gepaarter Stichproben zu vergleichen (mit Hilfe eines Entscheidungsdiagramms)?

