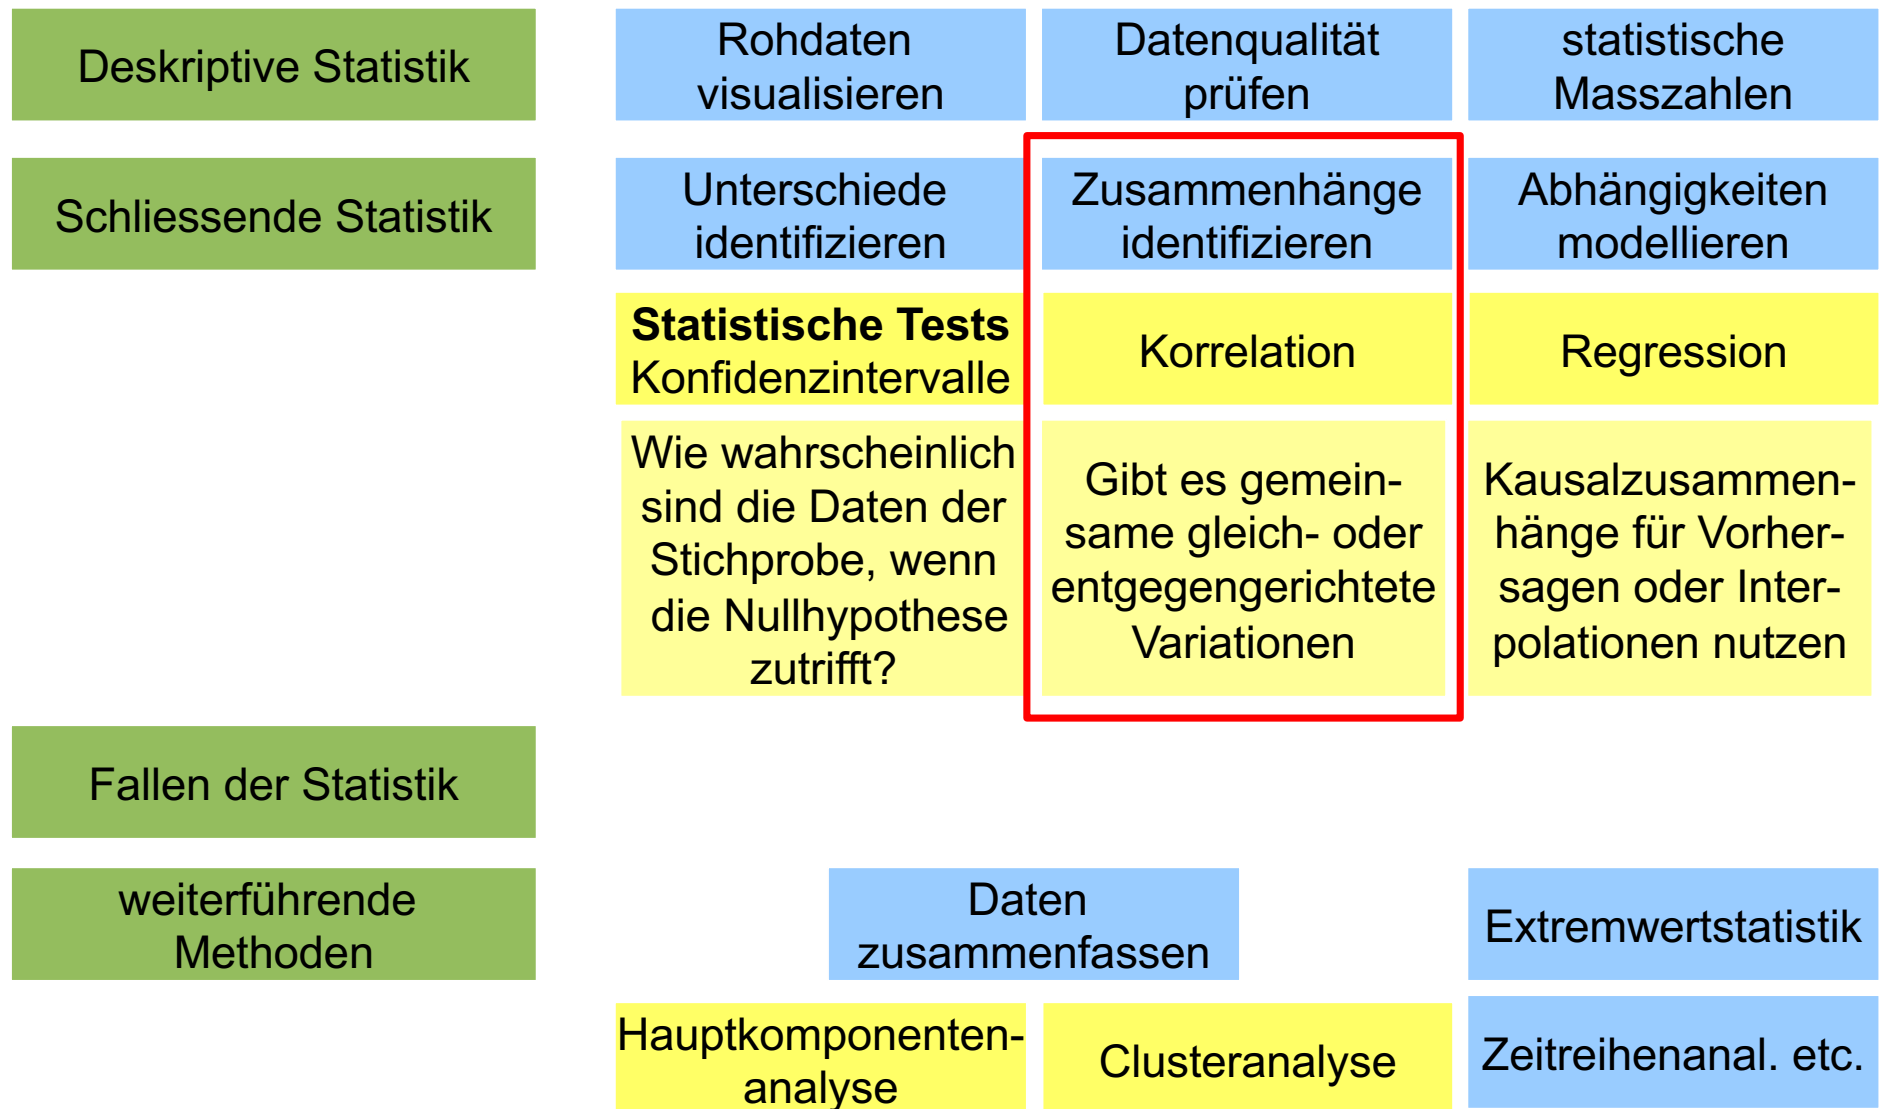


KORRELATION


Ernste Kap. 2, Anh. A5.1-A5.2;
Ewing I: Kap. 9

Statistische Datenanalyse





Beispiele von Beziehungen


Einfache Kausalbeziehung



Scheinrelation





Kovariation



Partielle Scheinrelation

Beispiel für konditionale Variablen



Korrelationsanalyse



Abbildung 1.3: Pfaddiagramm einer einfachen kausalen Beziehung



Abbildung 1.4: Pfaddiagramm einer Kovariation




Abbildung 1.5: Pfaddiagramm einer Scheinrelation




Abbildung 1.6: Pfaddiagramm einer partiellen Scheinrelation

- > Masszahl für die Stärke des **linearen** Zusammenhangs **metrischer** Variablen
- > sagt nichts über die Kausalität und Richtung des Zusammenhangs aus

Streudiagramme oder Scatterplots

Zusammenhänge zwischen zwei Variablen



Korrelationskoeffizient?

Pearson-Korrelation

Wie messen wir den Zusammenhang zweier Variablen?

1. Idee: Das Produkt der Anomalien

$$X_i^d = X_i - \mu_x ; Y_i^d = Y_i - \mu_y$$

$$\sum_{i=1}^N (X_i - \mu_x) (Y_i - \mu_y) = \sum_{i=1}^N X_i^d Y_i^d$$

Ist von Stichprobengrösse (n)
abhängig

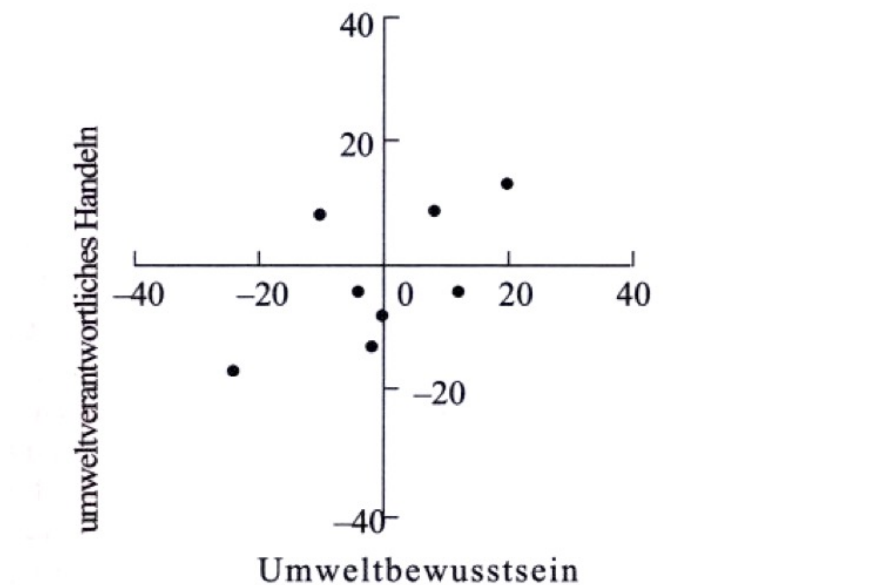


Abbildung 2.9: Transformation der ursprünglichen Werte zu Abweichungen vom Mittelwert

Pearson-Korrelation

2. Division durch Stichprobengrösse

Kovarianz zwischen Y und X

$$\sigma_{xy} = \frac{\sum_{i=1}^N (X_i - \mu_x)(Y_i - \mu_y)}{N}$$

Ist von den Einheiten abhängig

Pearson-Korrelation

3. Standardisierung

mit Standardabweichungen von X und Y

$$\rho_{xy} = \frac{\sum_{i=1}^N \frac{(X_i - \mu_x)}{\sigma_x} \frac{(Y_i - \mu_y)}{\sigma_y}}{N}$$

$$\sigma_x = \sqrt{\frac{\sum_{i=1}^N (X_i - \mu_x)^2}{N}} \text{ und}$$

$$\sigma_y = \sqrt{\frac{\sum_{i=1}^N (Y_i - \mu_y)^2}{N}}$$

Korrelationskoeffizient (Pearson)

$$\rho_{xy} = \frac{\sum_{i=1}^N (X_i - \mu_x) (Y_i - \mu_y)}{\sqrt{\sum_{i=1}^N (X_i - \mu_x)^2 \sum_{i=1}^N (Y_i - \mu_y)^2}}$$

Prüfung!

Pearson-Korrelation

- > Der Korrelationskoeffizient drückt das Verhältnis der beobachteten Kovarianz zur maximalen Kovarianz aus bzw.
- > Der Korrelationskoeffizient ist die bezüglich der Standardabweichung von X und Y normierte Kovarianz.

Korrelationskoeffizient (Pearson)

$$\rho_{xy} = \frac{\sum_{i=1}^N (X_i - \mu_x) (Y_i - \mu_y)}{\sqrt{\sum_{i=1}^N (X_i - \mu_x)^2 \sum_{i=1}^N (Y_i - \mu_y)^2}}$$

- > ρ (rho) ist der Standardbuchstabe für den Korrelationskoeffizienten der Grundgesamtheit
- > r für den Korrelationskoeffizienten der Stichprobe

Ausreisser




Abbildung 2.11: Einfluss eines Ausreissers auf den Korrelationskoeffizienten

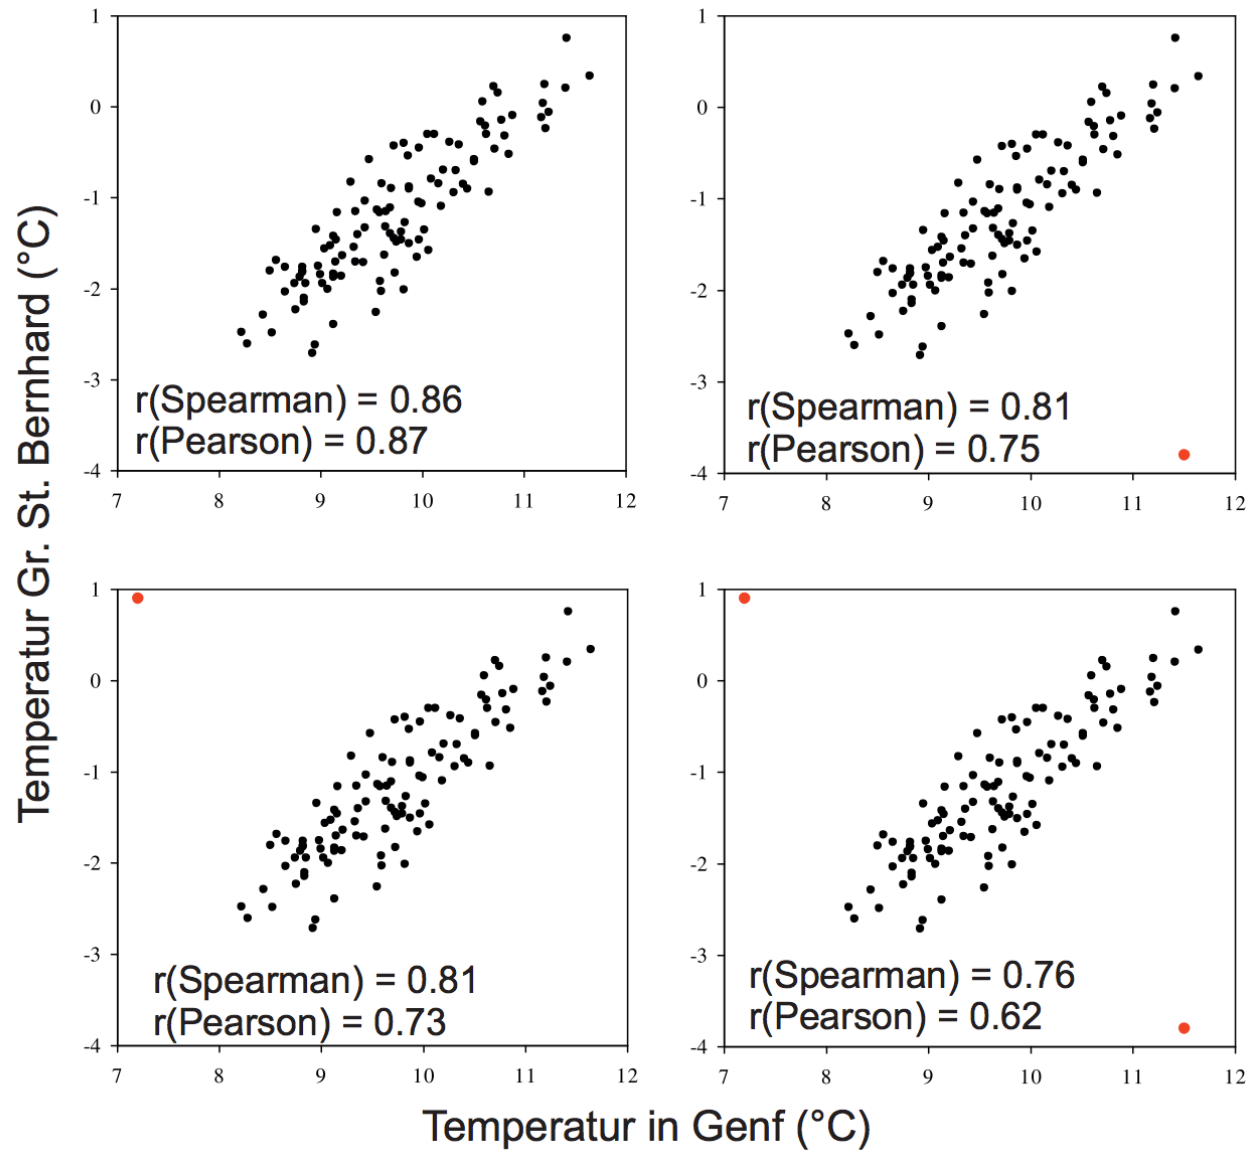
Spearman Rangkorrelation

- > Für ordinal skalierte Variablen kann der Rang eines Objekts (Beobachtung) in zwei Variablen verwendet werden:

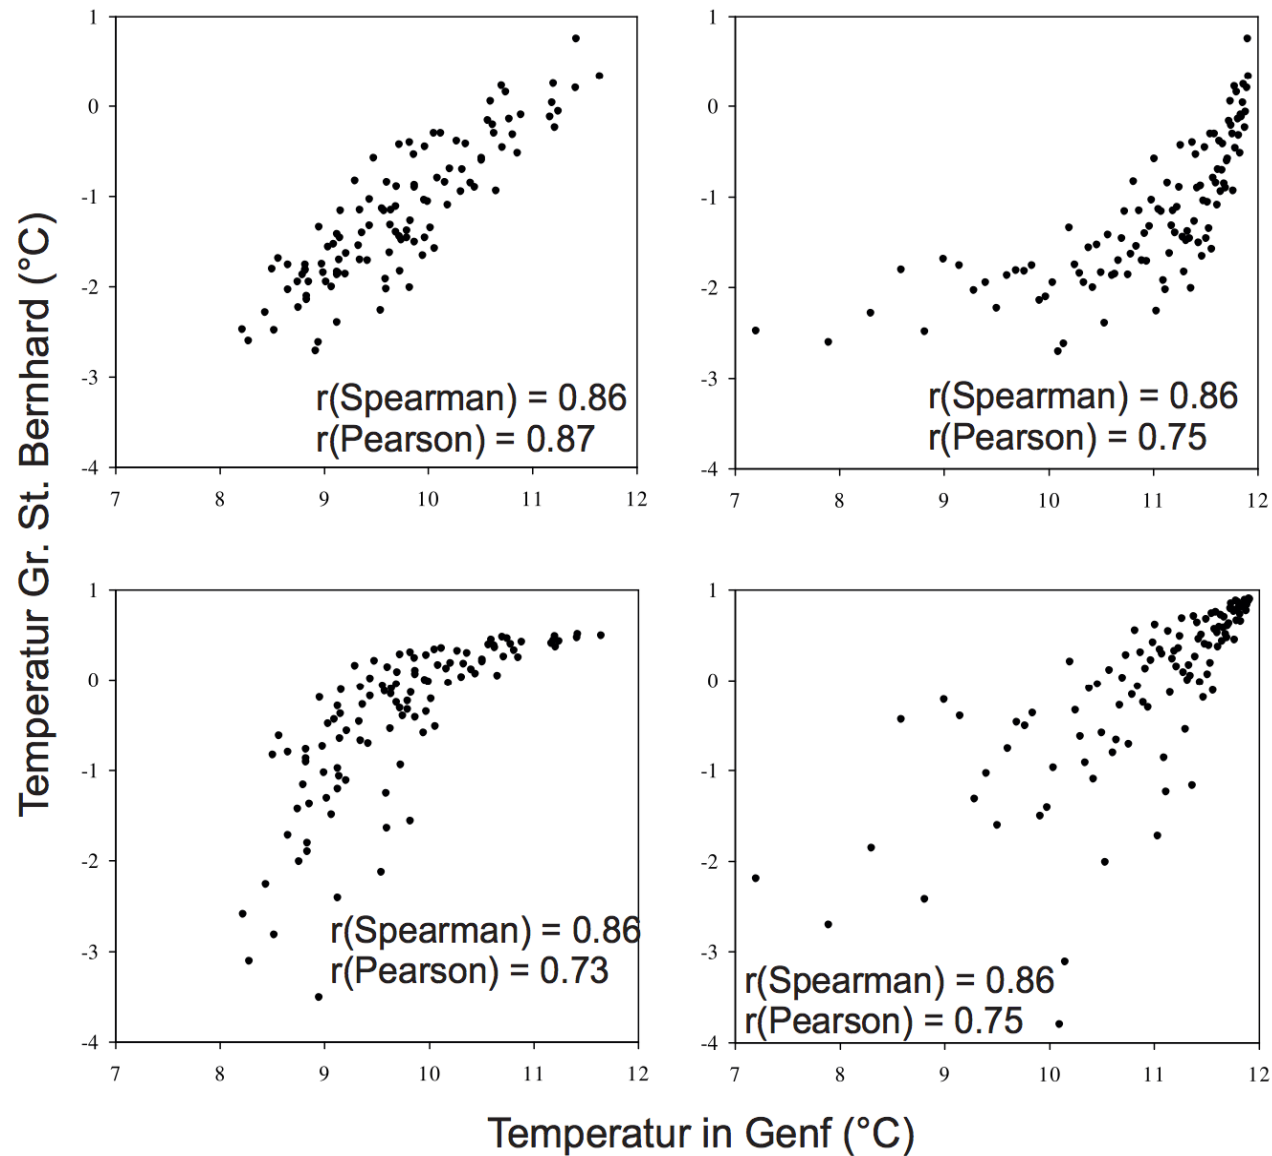
$$\rho = 1 - \frac{6 \cdot \sum_{i=1}^n (r_i - s_i)^2}{n^3 - n} \quad \text{(vereinfachte Formel, wenn jeder Rank nur einmal vergeben ist)}$$

- > r_i = Rang von Objekt i in der Variablen R , s_i = Rang von Objekt i in der Variablen S .
- > Der Spearman Rangkorrelationskoeffizient wird sehr oft auch für metrische Variablen verwendet, da er robust ist gegenüber Ausreißern. Im Zweifelsfall ist der Spearman-Koeffizient dem Pearson-Koeffizient vorzuziehen.

Spearman Rangkorrelation: **Ausreisser**



Spearman Rangkorrelation: **Nicht-Linearität**



Transformation der Achsen

- > Pearson-Korrelation: Misst Stärke des **linearen** Zusammenhangs, ist nicht sensitiv gegenüber linearen Transformationen (z.B. $y = a + bx$). Bei klarer (oder theoretisch begründeter) Nicht-linearität ist eine Transformation möglich.
- > Spearman: Misst Stärke eines **monotonen** Zusammenhangs, ist nicht sensitiv gegenüber monotonen Transformationen (z.B. $y = \ln(x)$)

Wann machen Transformationen Sinn?

- > Monotone Transformation nicht unbedingt (einfach Spearman statt Pearson verwenden)
- > Nicht-monotone Transformationen (z.B. $y = x^2$) können Sinn machen.
- > Alle Transformationen machen Sinn bei der Regression

Voraussetzungen für die Pearson-Korrelation

- > metrische Daten
- > beide Variablen annähernd normalverteilt
- > linearer Zusammenhang zwischen x und y
- > statistischer Zusammenhang zwischen x und y nur, wenn der ermittelte Korrelationskoeffizient signifikant von Null abweicht (t-Test)

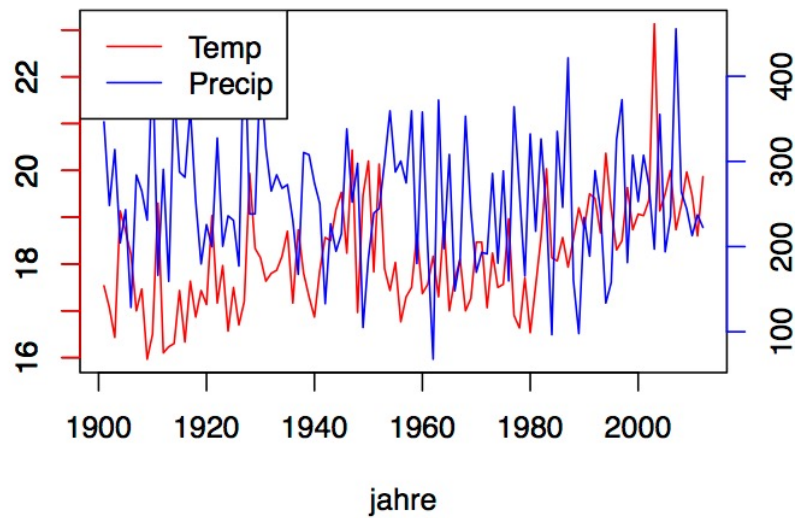
Rückschlüsse auf die Grundgesamtheit

Hypothesen:

- > H_0 : x und y sind unkorreliert $\rho_{xy} = 0$
- > H_A : x und y sind korreliert $\rho_{xy} \neq 0$
- > Annahme: Verteilung von x und y in der Grundgesamtheit ist eine bivariate Normalverteilung
- > Teststatistik: t-Test mit n-2 Freiheitsgraden



$$t = \frac{r_{xy} \sqrt{n-2}}{\sqrt{1-r_{xy}^2}}$$

Korrelation von Zeitreihen



Korrelationskoeffizient?

Korrelation von Zeitreihen



```
cor.test(sommer_temp_genf,sommer_precip_genf)
```

Pearson's product-moment correlation

data: sommer_temp_genf and sommer_precip_genf


t = -3.7533, df = 110, p-value = 0.0002805

alternative hypothesis: true correlation is not equal to 0

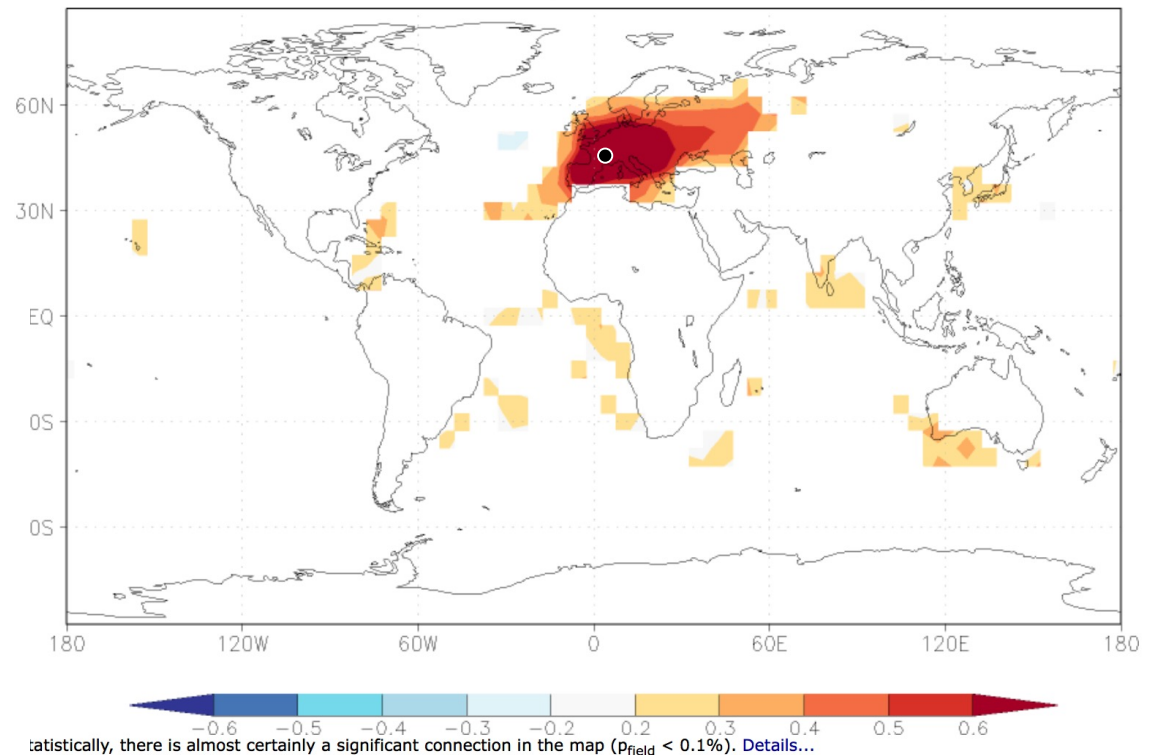
95 percent confidence interval: -0.4917509 -0.1614801

sample estimates: cor -0.33694

Autokorrelation in Zeit und Raum



corr Jan GENEVE-COINTR ghcn_v3_mean_temperature with Jan HadCRUT4.5 SST/T2m anom 1850:2016 p<10% (eps, pdf)
corr Jan GENEVE-COINTR ghcn_v3_mean_temperature
with Jan HadCRUT4.5 SST/T2m anom 1850:2016 p<10%



statistically, there is almost certainly a significant connection in the map ($p_{\text{field}} < 0.1\%$). [Details...](#)

Varianz-Kovarianzmatrix

- > Symmetrische Matrix mit den Varianzen in der Diagonalen und den Kovarianzen abseits der Diagonalen


$$\Sigma = \begin{bmatrix} \sigma_x^2 & \sigma_{xy} \\ \sigma_{xy} & \sigma_y^2 \end{bmatrix};$$

R Beispiel:

```
A <- matrix(c(2,3,1,-1,1,1,0,4,2,-1,0,0),nrow=4,ncol=3, byrow=T)
cor(A) # oder ,method="pearson", Pearson ist Standardeinstellung
cor(A,method="spearman")
```


Korrelation


- > “Dietary flavonoids ... which are widely present in cocoa ... have been shown to improve cognitive function. ... I wondered if there is a correlation between a country’s chocolate consumption and its population’s cognitive function ...” Messerli (2012)



Korrelation



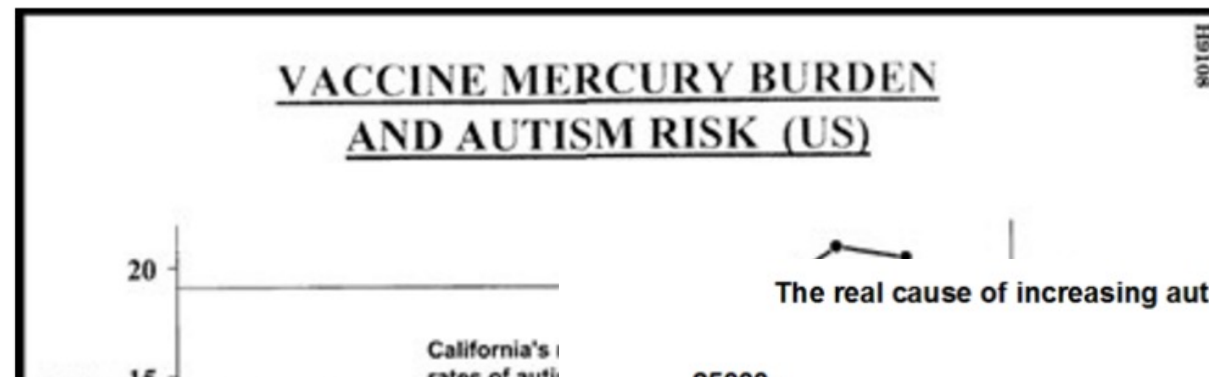
- > “Dietary flavonoids ... which are widely present in cocoa ... have been shown to improve cognitive function. ... I wondered if there is a correlation between a country’s chocolate consumption and its population’s cognitive function ...” Messerli (2012)

 $r = 0.79$



Korrelation \neq Kausalzusammenhang

- > Korrelation beschreibt nur die Stärke des Zusammenhangs, KEINE Information über Kausalzusammenhänge



Sources: Organic Trade Association, 2011 Organic Industry Survey; U.S. Department of Education, Office of Special Education Programs, Data Analysis System (DANS), OMB# 1820-0043: "Children with Disabilities Receiving Special Education Under Part B of the Individuals with Disabilities Education Act"

Take-home Message Korrelation

- > Korrelation beschreibt nur die Stärke des Zusammenhangs, KEINE Information über Kausalzusammenhänge
- > Pearson Korrelation nur für metrische Daten ohne Ausreisser und linearen Zusammenhang zwischen den beiden Variablen
- > Spearman Rangkorrelation für metrische und kategoriale Daten, robuster gegenüber Ausreissern und Nicht-Linearität
- > +1 heisst perfekter positiver Zusammenhang; 0 heisst kein Zusammenhang; -1 perfekter negativer Zusammenhang
- > zyklische Schwankungen und Trends können Korrelationskoeffizienten stark beeinflussen